

Rust

WPC

2025 年 11 月 3 日

目录

1	大模型时代的数据规模	2
2	性能分析	4

1 大模型时代的数据规模

数据规模 pytorch 在执行 GPU 上的运算时，是异步的，如果需要 GPU 计算的结果，需要调用 `torch.cuda.synchronize()` 来强制同步。如果需要随机数生成的结果可复现，需要设置随机数种子。

```
def set_seed(seed: int = 37) -> None:
    np.random.seed(seed)
    random.seed(seed)

    torch.manual_seed(seed)
    torch.cuda.manual_seed(seed)
    torch.backends.cudnn.deterministic = True
    torch.backends.cudnn.benchmark = False

    os.environ["PYTHONHASHSEED"] = str(seed)
    print(f"Random seed set to: {seed}")
```

GPU 锁频:

```
nvidia-smi --query-gpu=pstate,clocks.mem,clocks.sm,clocks.gr --format=csv
nvidia-smi --query-supported-clocks=gpu_name,mem,gr --format=csv
sudo nvidia-smi -pm 1
nvidia-smi -ac 8001,2100
```

CPU 锁频:

```
sudo apt install cpufrequtils

cpufreq-info
# 设置最大最小频率
sudo cpufreq-set -r -g performance
sudo cpufreq-set -r -d 2.1Ghz
sudo cpufreq-set -r -u 2.1Ghz
```

测量程序运行时间

```
time.perf_counter() //单位为s

torch.cuda.synchronize()
start=torch.cuda.Event(enable_timing=True)
end=torch.cuda.Event(enable_timing=True)

start.record()
# 运行代码
end.record()
torch.cuda.synchronize()

print(f"{start.elapsed_time(end)}ms")
```

2 性能分析

```
import torch
import torchvision.models as models
from torch.profiler import profile, record_function, ProfilerActivity

model = models.resnet18().cuda()
inputs = torch.randn(5, 3, 224, 224, device="cuda")

with profile(
    activities=[ProfilerActivity.CPU, ProfilerActivity.CUDA],
    profile_memory=True,
) as prof:
    with record_function("model_inference"):
        model(inputs)

prof.export_chrome_trace("trace.json")
print(prof.key_averages().table(sort_by="cuda_time_total", row_limit=10))
```

[perfetto trace viewer](#)